字节跳动 Seed 大模型

标注模板体验优化



目录

CONTENTS

1 **Marscode-SFT**

标注工艺动线优化

2 **Marscode RL**

新标注工艺优化

3 **Search SFT**

开放题队列体验优

4 **Seed 众测**

模拟评测→真实环境评测

5 **GlobalData 众测**

Search众测任务、Rubrics、标注难题

Marscode-SFT

用户动线优化

01

Marscode-SFT 标注模板体验优化

优化前



优化后



关键数据收益：模板优化后，交付人效提升2**%，累计交付1**w

体验优化后问卷回收情况：模板交互有优化后，作业人员对模板的体验满意度提升10.4%

效率提升：80.49%的调研对象认为在作业界面优化后，整体答题效率有所提升，其中超半数人员认为「查看意图识别结果」、「阅读及选择预标答案」及「阅读前置对话」这三个部分的操作效率有提升。

工艺1生产的数据：模型在aider评测集得分提升了1*%，工程开发类的题目得分增长3**%；

工艺2生产的数据：模型在aider评测集得分提升了8**%，工程开发类的题目得分增长1***%

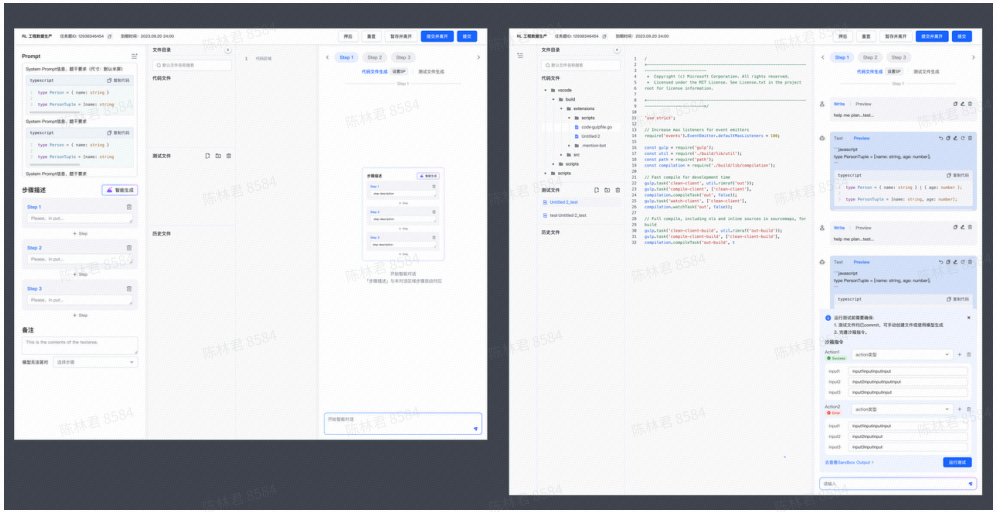
Marscode RL

新标注工艺优化

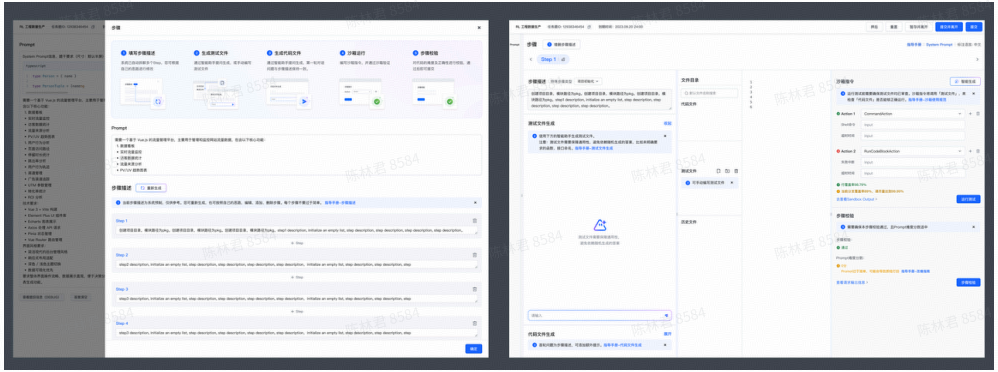
02

Marscode RL 标注模板体验优化

Before



After



优化前后对比：基于Golang、Python、前端 外包及众包标注员访谈反馈，结合问卷及oncall反馈，重新理解梳理用户高频板块使用场景，优化模板用户操作步骤动线。

增加辅助标注及预标能力，提升标注员读写效率。

允许标注员分步提交，以提高标注员答题动力，前1-2步通常比较简单，提前拿钱，以更好的激励用户

关键数据收益：

累计质检通过Step数量1**** Step，对最近提交的2****step进行通用性回扫，数据质量问题有较大提升。

拆分STEP后AHT降低69% （平均作业时长9**-2** h/次）老用户，平均每STEP的作业时间约降低20%

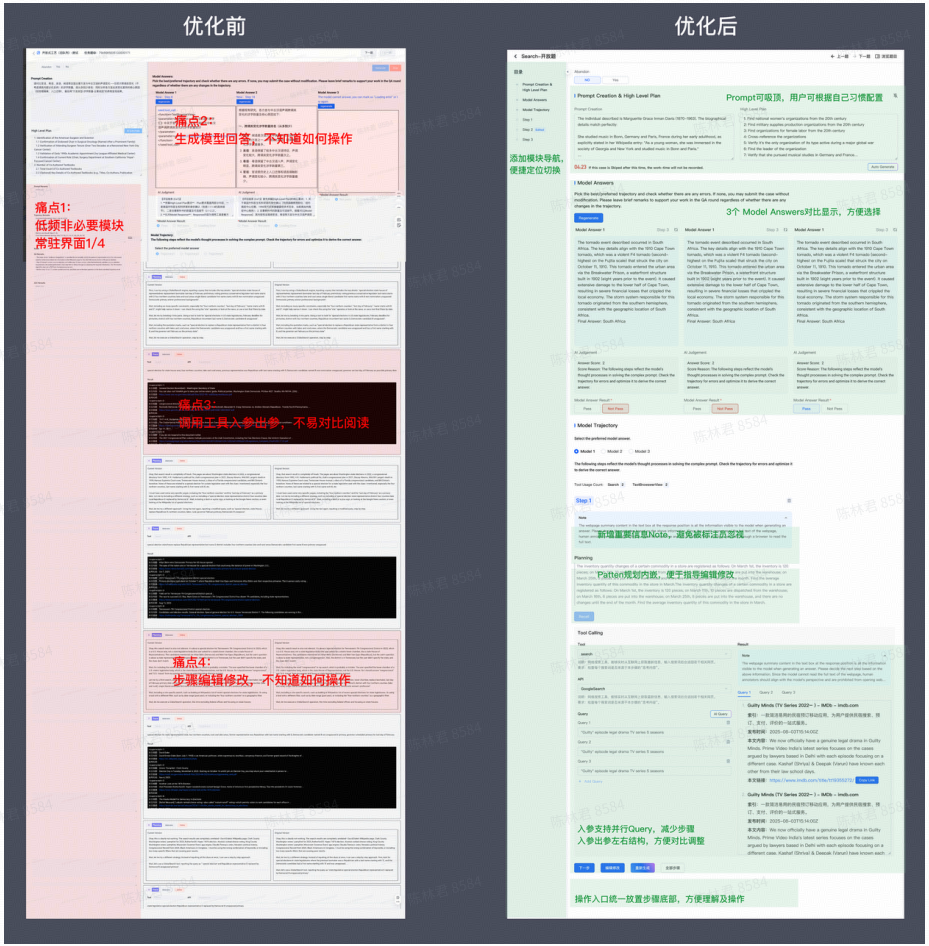
通过用户调研：对于拆分STEP-大部分用户认为拆分STEP能够提效；对于预制题-大部分新人认为预制好题目能够提供解题思路，提升首次提交成功率；

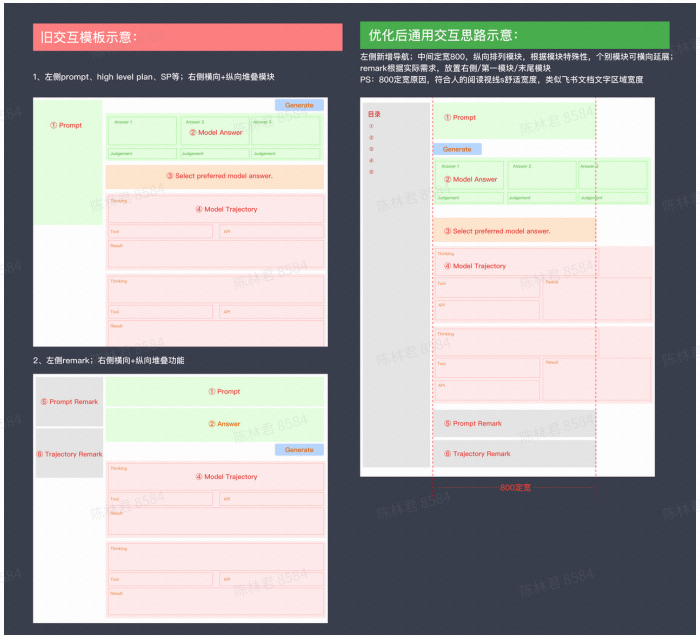
Search SFT

开放题队列体验优

03

Search SFT 标注模板体验优化





优化前后对比：Search-SFT开放题队列体验优化，解决交互动线杂乱，阅读困难，数据生产效率低的问题。

亮点&数据：SFT新工艺收到业务侧正向反馈，作业时长AHT显著下降：-2**%

泛化性验证实验：实验开放题数据加到封闭题模型上，表明对封闭题有明显的泛化效果（Bo1 6**→1** Bo5 1**→2**）（解释：bo1评测集，只跑一次；bo5 是跑 5 次选做好那次）

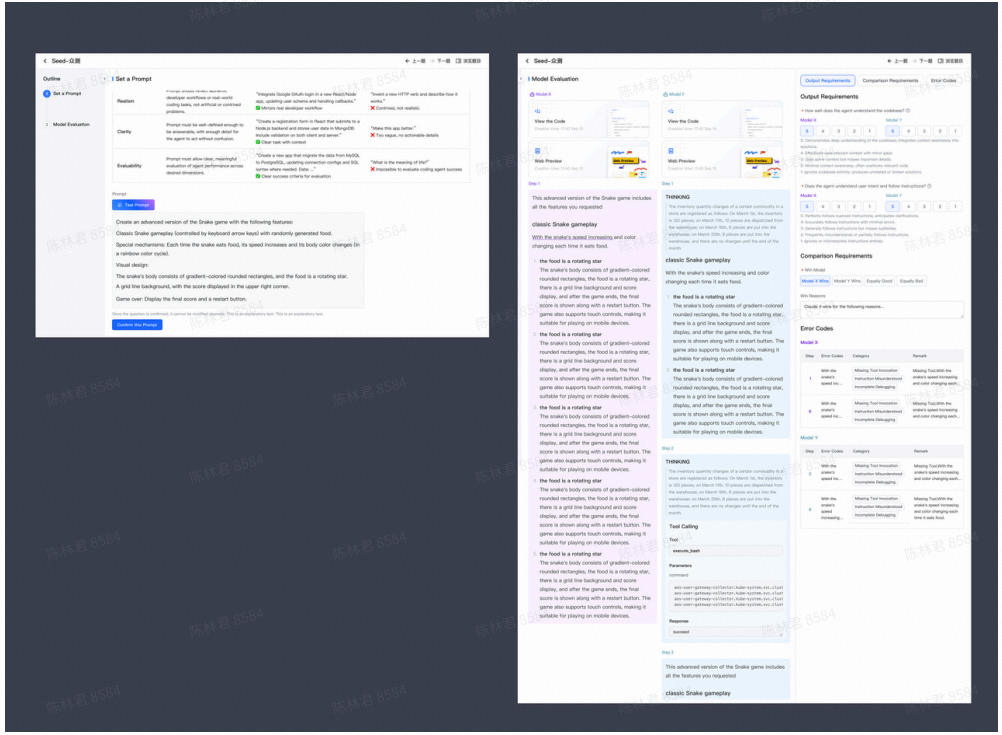
Seed 众测

模拟评测→真实环境评测

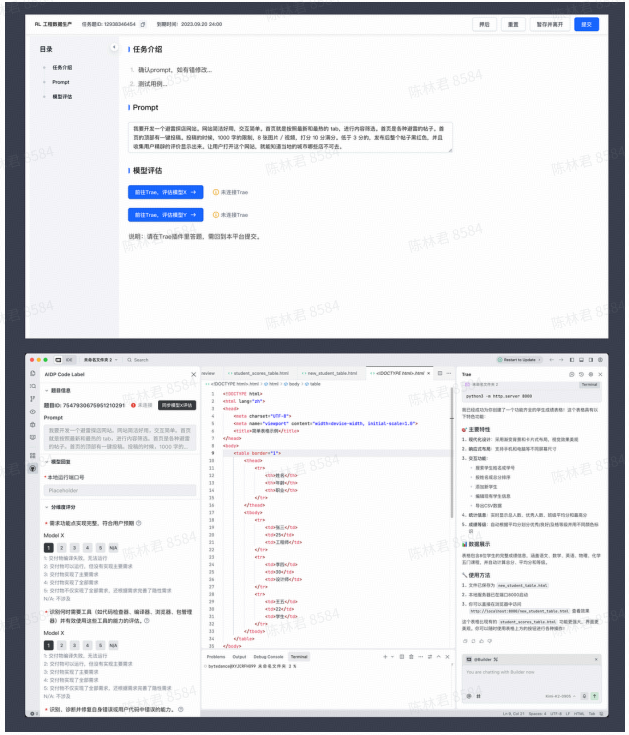
04

Marscode RL 标注模板突破性创新

Before



After



优化前后：在AIDP和Trae中搭建模型评测流程。构建支持专家实时交互的评测平台，建立用户视角下真实开发工作流中的模型评测集，解决现有评测体系与用户真实需求的断层问题。

亮点&数据：单题标注：AHT 2h/题 → 30min/题，效率提升 400%；单题质检：AHT 30min/题 → 12.5min/题，效率提升240%

GlobalData 众测

Search众测任务、Rubrics、标注难题

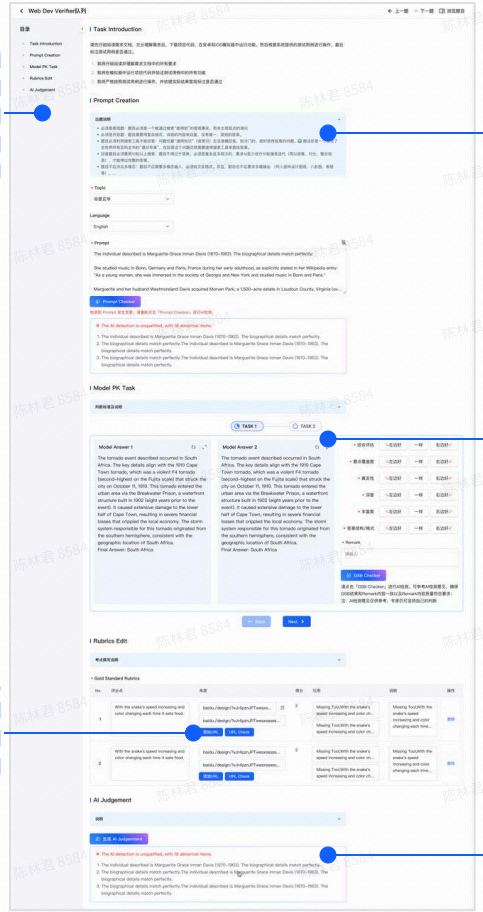
05

Search众测高频模板体验优化

Before



After



优化点1

增加左侧目录导航，起到概览题目的作用，同时方便快速定位题目板块。

优化点2

新增说明，将培训手册里的关键信息提炼至此，专家可更快速上手作答。

优化收益：产出评测数据6**条，业务侧发现 3*error，最新deep research VS 线上，胜率5*%，内部search VS GPT 5.2，胜率 8*%

优化点3

左右对照作答，更好的适配不同机型的屏幕。更方便对比模型评分。

优化点4

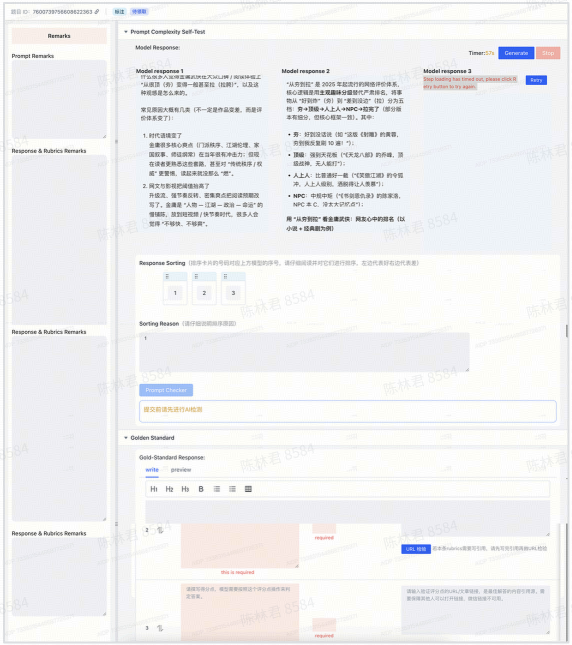
rubrics 多个来源分开填写，回收的数据更清晰。

优化点5

新增AI辅助质检，帮助专家更高质量的完成作答。

Rubrics 标注工艺优化

Before



After



优化点1

增加左侧目录导航，起到概览题目的作用，同时方便快速定位题目板块。

优化点2

新增说明，将培训手册里的关键信息提炼至此，专家可更快速上手作答。

优化点3

把分散的remark板块，集中汇总到右侧区域，类似文档的评论区，各环节反馈一目了然。

优化收益：支持标注PE自动直接及交互提效优化，标注员主观反馈节约耗时约0.5h，AHT观测显著下降**%

优化点4

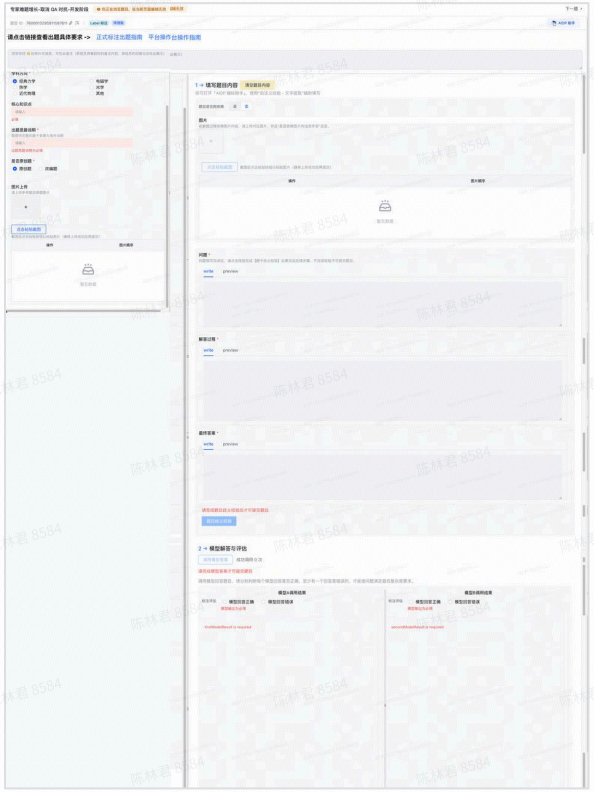
Rubrics以卡片形式呈现，打破表格的固有思维，提高阅读效率。

优化点5

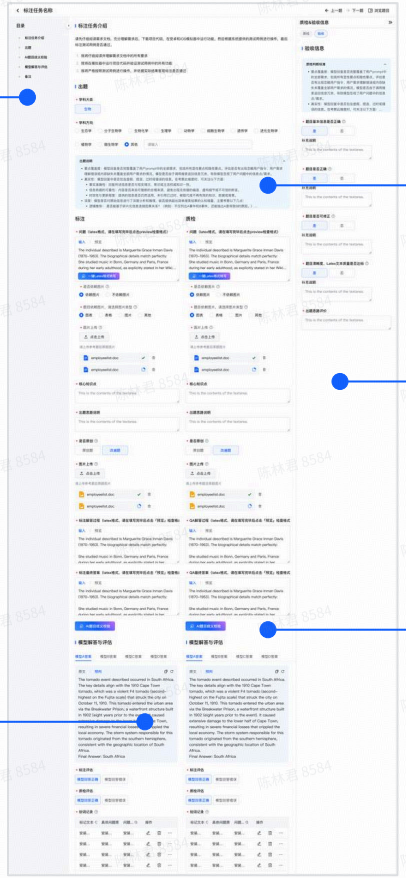
新增AI辅助质检，帮助专家更高质量的完成作答。

Search众测任务

Before



After



优化点1

增加左侧目录导航，起到概览题目的作用，同时方便快速定位题目板块。题目作答顺序从折线型，变纵向作答，动线更简单。

优化点2

新增说明，将培训手册里的关键信息提炼至此，专家可更快速上手作答。

优化点3

把分散的remark板块，集中汇总到右侧区域，类似文档的评论区，各环节反馈一目了然。

优化点5

新增AI辅助质检，帮助专家更高质量的完成作答。

优化收益：POC访谈及用户反馈，新标注界面清晰易懂，阅读及输入作答更友好，学习成本大大降低。

优化点4

背靠背标注结果对比，一目了然。

谢谢